

SemEval_2015_Task_3 实验报告

本实验在 SemEval_2015_Task_3¹数据集上使用规则提取特征并使用 svm 和随机森林两种方法在提取特征的基础上进行分类。

- 特征提取

本实验参照文中的思路提取特征。

在 A 任务中，每个 question-comment pair 有 100 维特征。其中关于问题（QBody 字段）与回答（CBody 字段）本身各有 25 维特征，见表 1，在提取这些特征之前先去掉了文中的所有链接，但没有去掉 html 标签。question-comment pair 整体还有 50 个特征，见表 2。

特征描述	形式	维数
标签数（以<>数量中较少的估计）	计数	1
最长单词长度	计数	1
平均单词长度	数值	1
单词数量	计数	1
句子数量（以问号、句号、叹号总数估计）	计数	1
平均每句单词数量	数值	1
大写单词数量	计数	1
命名实体数量	计数	1
no 的数量	计数	1
yes 的数量	计数	1
thank, thanks 的数量	计数	1
please 的数量	计数	1
may, might, could, can, would, will 的数量	计数	1
问号的数量	计数	1
叹号的数量	计数	1
名词、动词、代词、疑问词、外来词的数量	计数	5

¹ <http://alt.qcri.org/semeval2015/task3/>

名词、动词、代词、疑问词、外来词的频率	比率	5
---------------------	----	---

表 1 问题和回答文本分别统计的特征

特征描述	形式	维数
问题和回答中的图数和链接数	计数	4
回答是否是第一个或最后一个	布尔	2
当前及前后回答的 USERID 是否和提问者相同	布尔	3
问题是否为是否类问题	布尔	1
问题类型 (QCATEGORY)	one-hot	27
回答的 title 是否问 “Re : ” + 问题 title	布尔	1
问题和回答相同的 uni bi tri gram 数	计数	3
上数相对于问题长度和回答长度的比值	比率	6
问题和回答的 uni bi tri gram 的 one-hot 向量余弦值	数值	3

表 2 问题和回答联合统计的特征

由于官网的评价脚本中，A 任务只考虑 Good、bad 和 Potential 三个类别，所以在标记标签时，尝试了两种标签标记方式：A-full 是标全 6 类的。而 A-sim 是只标记 3 类的。

在 B 任务中使用的特征和 A 任务中相同，不过是以题为单位。故每道题的特征向量是 A-sim 标记下 svm 训练结果中标记为 good 的选项的特征向量的均值。

● 实验设置

在具体实现时，使用的工具 libsvm²和 xgboost³。分词、词性标注和命名实体识别等使用 nltk⁴。

简单调参后，两个任务均使用线性核 SVM，task-A 的两种标注的参数-c 均为 0.5，task-B 的参数-c 为 1。而在随机森林时，两个任务均使用 multi:softmax 作为目标函数，最大树深为 5，学习率 eta 为 0.2，训练轮数为 50 轮。

评价时，task-A 和官网上评价脚本相同，只考虑 3 类。task-A 和 task-B 的评价指标均为 macro-f1 和 accuracy。

● 实验结果

² <http://www.csie.ntu.edu.tw/~cjlin/libsvm/>

³ <http://xgboost.readthedocs.io/en/latest/>

⁴ <http://nltk.org>

Task-A 在验证集和测试集上的实验结果如表 3 所示，Task-B 在验证集和测试集上的实验结果如表 4 所示。

	macro-F1	Acc	F1-Good	F1-Pot.	F1-Bad
A-full-svm-dev	47.39%	67.42%	76.05%	0.00%	61.66%
A-full-svm-test	49.41%	70.34%	76.70%	0.00%	67.99%
A-Sim-svm-dev	48.46%	69.36%	76.60%	0.00%	68.49%
A-Sim-svm-test	50.56%	72.77%	77.86%	0.00%	73.42%
A-full-rf-dev	48.51%	68.94%	77.12%	0.00%	64.96%
A-full-rf-test	49.57%	70.70%	77.08%	0.00%	68.49%
A-Sim-rf-dev	48.77%	69.85%	77.40%	0.00%	68.79%
A-Sim-rf-test	50.24%	72.27%	77.16%	0.00%	73.17%

Task-A 上的实验结果

	macro-F1	Acc	F1-Yes	F1-Unsure	F1-No
B-svm-dev	54.32%	55.88%	66.67%	40.00%	50.00%
B-svm-test	43.39%	51.72%	62.86%	46.15%	20.00%
B-rf-dev	52.77%	55.88%	68.75%	45.45%	42.86%
B-rf-test	57.50%	68.97%	82.35%	58.82%	28.57%

Task-B 上的实验结果

● 一点分析

由于本实验采用的机器学习方法并没有针对 macro-F1 做特殊地优化，在 Task-A 上，小类 Pot.的效果很差。导致了本实验 Accuracy 看起来还不错但 macro-F1 明显偏低。

Xgboost 在 TaskB 上的效果莫名地好。不过可能也是由于 Task-B 的数据集较小导致的意外吧。

但是网上下载的数据集的测试集规模和 SemEval-2015 评测报告中写的不一样。

GitHub 地址：

https://github.com/Erutan-pku/SemEval_2015_Task_3

ⁱ Hou, Yongshuai, et al. "HITSZ-ICRC: Exploiting Classification Approach for Answer Selection in Community Question Answering." *International Workshop on Semantic Evaluation* 2015:196-202.

